



МОСКОВСКИЙ УНИВЕРСИТЕТ ИМЕНИ С.Ю. ВИТТЕ

Факультет Информационных технологий
Кафедра Кафедра информационных систем
Направление подготовки/Специальность Прикладная информатика

ОТЧЕТ

о прохождении

Производственная практика

/вид практики/

Эксплуатационная практика

/тип практики/

Студента Коломиеца Филиппа Андреевича
(фамилия, имя, отчество)

Место прохождения практики ЧОУВО «МУ им. С.Ю. Витте»

Период прохождения практики с 20.04.2026 г. по 31.05.2026 г.

г. Москва 2026 г.

Оглавление

Оглавление	2
Введение	3
1. Основная часть	4
2. Анализ предметной области	4
2.1. Выбор и настройка среды разработки Python	4
2.2. Анализ применения нейросетей для обработки научных текстов	4
2.3. Анализ методов поиска утверждений о существовании и единственности	5
2.4. Анализ структуры научных pdf документов	5
2.5. Вывод по разделу	6
3. Разработка системы подготовки датасета	7
3.1. Разработка структуры программы	7
3.2. Извлечение и обработка текста из pdf документов	8
3.2.1. Получение и чтение pdf файлов	8
3.2.2. Очистка и нормализация текста	9
3.2.3. Формирование текстовых фрагментов	10
3.3. Реализация поиска утверждений о существовании и единственности	11
3.4. Использование нейросети для анализа текста	12
3.4.1. Подключение модели через Ollama	13
3.4.2. Определение названия статьи и авторов	14
3.5. Формирование итогового датасета	15
3.6. Анализ результатов работы программы	16
3.7. Вывод по разделу	18
4. Заключение	19
5. Список использованной литературы	20

Введение

Производственная практика проходила в Московском университете им. С.Ю. Витте на кафедре информационных систем и технологий. В ходе практики рассматривались возможности применения нейросетевых технологий для обработки научных текстов и подготовки специального датасета.

Основной задачей работы являлось создание программы на языке Python для извлечения текстовой информации из научных pdf документов. Уделялось внимание поиску утверждений о существовании и единственности решений в математических статьях, а также формированию структурированного датасета для дальнейшего анализа.

Целью практики являлось получение практических навыков разработки программных решений с применением методов интеллектуального анализа данных и инструментов обработки текста.

Для достижения поставленной цели были определены следующие задачи:

- закрепление теоретических знаний;
- изучение возможностей Python для обработки научных документов;
- разработка программы для извлечения и очистки текста;
- реализация поиска тематических текстовых фрагментов;
- формирование итогового датасета;
- использование нейросетевой модели для анализа содержимого статей;
- анализ результатов работы программы.

В процессе выполнения работы использовались библиотеки для обработки pdf документов, инструменты нормализации текста, а также локальная языковая модель, подключённая через Ollama.

В рамках практики предусматривается разработка программного средства для формирования датасета на основе научных математических публикаций. Основной задачей является автоматическое выявление и сохранение фрагментов текста, содержащих утверждения о существовании и единственности рассматриваемых объектов, решений или математических конструкций.

Качество полученного результата предполагается оценивать по нескольким критериям. Сформированный датасет должен содержать корректно выделенные текстовые фрагменты без посторонних символов и значительных искажений исходного текста. Для каждого найденного фрагмента должны присутствовать сведения об авторах публикации и название научной статьи. Дополнительно оценивается соответствие найденных фрагментов тематике существования и единственности, а также корректность определения начальной и конечной позиции каждого фрагмента в тексте документа.

1. Основная часть

2. Анализ предметной области

2.1. Выбор и настройка среды разработки Python

Для разработки программы был выбран язык Python, так как он хорошо подходит для обработки текста и работы с данными. Кроме этого, для Python существует большое количество библиотек для анализа документов и работы с нейросетями.

Разработка выполнялась в среде Pycharm. В ходе работы были установлены библиотеки fitz, natasha и ollama. Библиотека fitz использовалась для чтения pdf документов, natasha - для обработки текста, а ollama - для подключения локальной языковой модели.

Также была настроена рабочая папка проекта, содержащая pdf файлы, основной файл программы и итоговый датасет в формате JSONL. После

настройки среды была проведена проверка корректности работы библиотек и обработки документов.

2.2. Анализ применения нейросетей для обработки научных текстов

Сейчас нейросети активно применяются для обработки текстовой информации. Особенно это актуально при работе с научными статьями, так как такие документы содержат большое количество сложных терминов, формул и специализированных выражений.

При помощи нейросетевых моделей можно автоматически находить нужные фрагменты текста, определять тему документа, извлекать ключевую информацию и выполнять анализ содержания статьи. Это позволяет сократить время обработки большого количества научных публикаций.

В данной работе нейросетевая модель использовалась для определения названия статьи и авторов по содержанию первой страницы документа. Подключение модели выполнялось локально через Ollama. Такой подход позволил автоматизировать часть обработки научных текстов и упростить формирование итогового датасета.

2.3. Анализ методов поиска утверждений о существовании и единственности

При анализе научных математических текстов одной из основных задач является поиск утверждений, связанных с существованием и единственностью решений. Чаще всего подобные фрагменты встречаются в формулировках теорем, лемм, доказательств и выводов.

Для поиска таких утверждений можно использовать разные методы. Одним из вариантов является полный анализ текста нейросетевой моделью, однако такой способ требует больших вычислительных ресурсов и занимает больше времени при обработке большого количества документов.

В данной работе был использован более простой подход, основанный на поиске ключевых корней слов. Для этого анализировались слова, содержащие корни “существ” и “единствен”. Такой метод позволил находить фрагменты

текста, связанные с существованием решения, условиями существования и единственностью.

После нахождения нужного блока дополнительно формировался смысловой фрагмент из соседних частей текста. Это позволило сохранить связность предложений и получить более понятный результат для последующего формирования датасета.

2.4. Анализ структуры научных pdf документов

Научные pdf документы имеют сложную структуру и содержат текст, формулы, специальные символы и различные элементы оформления. Из-за этого при извлечении текста могут появляться лишние пробелы, переносы строк и ошибки в символах.

Большинство рассмотренных статей содержали название, авторов, аннотацию, основной текст и математические выражения. Основная сложность обработки заключалась в сохранении связности текста после извлечения из PDF.

Для чтения документов использовалась библиотека `fitz`, позволяющая получать текст по страницам и отдельным блокам. После извлечения выполнялась очистка и нормализация текста для дальнейшего поиска нужных фрагментов.

2.5. Вывод по разделу

В данном разделе были рассмотрены способы обработки научных текстов и особенности работы с pdf документами. Также были изучены инструменты Python, необходимые для создания программы и подготовки датасета.

Проведённый анализ помог понять, каким образом можно находить утверждения о существовании и единственности и подготавливать текст для дальнейшей обработки.

Выводы по разделу 1

Выводы	Сформированные компетенции
Изучены особенности обработки научных pdf документов и подготовки текстовых данных для дальнейшего анализа	ПК-1. Способность разработки прикладного программного обеспечения, автоматизации работы с базами данных и документами, программирования бизнес-логики приложений, интеграции разнородных данных
Проведен анализ методов поиска математических оценок, границ и неравенств в научных текстах	
Выполнено исследование способов применения нейросетевых моделей при извлечении метаданных документов	ПК-7. Способностью использовать отечественные и международные стандарты при проектировании и обеспечении качества прикладного программного обеспечения

3. Разработка системы подготовки датасета

3.1. Разработка структуры программы

Разработка программы началась с создания основного класса DatasetBuilder. В него были вынесены все действия, необходимые для подготовки датасета, поиск pdf файлов, чтение текста, очистка данных, поиск нужных фрагментов и сохранение результата.

Такая структура была выбрана для того, чтобы программа не состояла из отдельных несвязанных частей. Все основные методы находятся внутри одного класса и работают с общими данными, папкой с файлами, списком pdf документов, ключевыми корнями слов и моделью для анализа текста.

В начале работы задаётся папка assets, где находятся научные статьи, а также список корней существ и единствен. После этого создаётся объект класса DatasetBuilder, а запуск программы выполняется через метод run(). Это упростило дальнейшую разработку и проверку работы программы.

```
class DatasetBuilder:  
  
    builder = DatasetBuilder(folder, roots)  
  
    builder.run()
```

На рисунке 1. показана общая структура разработанной программы.




Рисунок 1.

3.2. Извлечение и обработка текста из pdf документов

3.2.1. Получение и чтение pdf файлов

На данном этапе была реализована загрузка pdf файлов из рабочей папки проекта. Для этого в программе используется папка `assets`, в которую заранее помещаются научные статьи для обработки. Программа проходит по содержимому этой папки и выбирает только те файлы, которые имеют расширение `.pdf`.

Для получения списка документов был создан метод `get_pdf_files()`. Он проверяет имена файлов, формирует полный путь к каждому pdf документу и добавляет его в общий список. После этого программа может обрабатывать все найденные статьи.

```
def get_pdf_files(self):
    files = []

    for file_name in os.listdir(self.folder):
        if file_name.endswith(".pdf"):
            full_path = self.folder + "/" + file_name

            files.append(full_path)

    return files
```

После получения списка файлов выполняется чтение каждого pdf документа. Для этого используется библиотека `fitz`, которая открывает файл и позволяет проходить по его страницам. В дальнейшем текст с каждой страницы передаётся на очистку и поиск нужных фрагментов.

```
def read_pdf(self, pdf_path):
    document = fitz.open(pdf_path)

    found_blocks = []

    first_page_text = ""
    global_index = 0
    for page_number in range(len(document)):
        page = document[page_number]
```

3.2.2. Очистка и нормализация текста

После извлечения текста из pdf документа его нельзя сразу использовать для датасета. В тексте часто остаются переносы строк, лишние пробелы, табуляции и знаки, которые мешают дальнейшему поиску нужных слов. Поэтому в программе был добавлен отдельный этап очистки.

Для очистки отдельных слов используется метод `clean_word()`. Он убирает лишние знаки препинания и приводит слово к более удобному виду для проверки.

```
def clean_word(self, dirty_word):
    symbols_to_remove = '.,!?:;()[]{}"«»-' + ""
    cleaned = dirty_word

    for symbol in symbols_to_remove:
        cleaned = cleaned.replace(symbol, "")

    return cleaned
```

Также в программе есть метод `clean_block_text()`. Он очищает уже целый текстовый блок, убирает переносы строк, табуляции и повторяющиеся пробелы.

```
def clean_block_text(self, block_text):
    cleaned_block = block_text.strip()

    cleaned_block = cleaned_block.replace("\n", " ")

    cleaned_block = cleaned_block.replace("\t", " ")

    cleaned_block = cleaned_block.replace("- ", "")

    while " " in cleaned_block:
        cleaned_block = cleaned_block.replace(" ", " ")

    return cleaned_block
```

3.2.3. Формирование текстовых фрагментов

После очистки текста программа формирует отдельные фрагменты, которые потом попадают в датасет. Это нужно для того, чтобы сохранить не просто найденное слово, а небольшой смысловой кусок текста вокруг него.

В методе `read_pdf()` каждый текстовый блок получает свой начальный и конечный индекс. За счёт этого в итоговом файле можно видеть, где примерно находился найденный фрагмент.

```
block_data = {
    "text": cleaned_block,
    "start_index": start_index,
    "end_index": end_index
}

page_blocks.append(block_data)
```

Программа проверяет каждый блок. Если в нём найден нужный корень слова, создаётся итоговый фрагмент с номером страницы, типом данных, индексами и самим текстом.

```
result_data = {
    "page": page_number + 1,
    "type": "text",
    "start_index": sense_fragment["start_index"],
    "end_index": sense_fragment["end_index"],
    "fragment": sense_fragment["text"]
}

found_blocks.append(result_data)
```

Сохраняем результат в удобном виде. В датасет попадает не весь документ, а только те части статьи, где есть нужные высказывания о существовании и единственности.

3.3. Реализация поиска утверждений о существовании и единственности

Поиск нужных утверждений в программе сделан через проверку корней слов. Для этой задачи были выбраны корни существ и единствен, так как они чаще всего встречаются в формулировках про существование решения и его единственность.

```
roots = [  
    "существ",  
    "единствен"  
]
```

Текстовый блок разбивается на отдельные слова. Слово очищается от лишних знаков, переводится в нижний регистр и сравнивается с заданными корнями.

```
def block_has_root(self, block_text):  
    words = block_text.split()  
  
    for one_word in words:  
        cleaned_word = self.clean_word(one_word)  
  
        lowered_word = cleaned_word.lower()  
  
        for root in self.roots:  
            if root in lowered_word:  
                return True  
    return False
```

Программа считает блок подходящим и добавляет его дальше в обработку. Такой способ простой, но для данной задачи он подходит, потому что в математических статьях нужные формулировки обычно содержат слова.

3.4. Использование нейросети для анализа текста

В программе нейросети используется для получения данных о научной статье. Она помогает определить название работы и авторов по тексту первой страницы pdf документа. Вот так, данные не приходится выписывать вручную для каждой статьи.

Для подключения модели используется библиотека ollama. В программе была выбрана локальная модель qwen2.5:7b.

```
self.model = "qwen2.5:7b"
```

Обращение к модели выполняется через отдельный метод ask_ollama(). В него передаётся текстовый запрос, после чего модель возвращает ответ.

```
def ask_ollama(self, prompt):
    response = ollama.generate(
        model=self.model,
        prompt=prompt
    )

    answer = response["response"]

    return answer.strip()
```

Метод используется при обработке первой страницы статьи. В запросе программе указывается, что нужно найти название статьи и авторов.

```
def find_source_info(self, first_page_text):
    prompt = (
        "Найди название научной статьи и автора или авторов. "
        "Ищи только в тексте первой страницы. "
        "Ответь строго в таком виде:\n"
        "Название: ...\n"
        "Авторы: ...\n"
        "Если данных нет, напиши unknown.\n\n"
        + first_page_text[:3000]
    )
```

3.4.1. Подключение модели через Ollama

Для работы с нейросетевой моделью в программе использовалась система Ollama. Она позволяет запускать языковые модели локально на компьютере и обращаться к ним через код.

Была подключена библиотека ollama.

```
import ollama
```

После этого в классе DatasetBuilder задаётся используемая модель. В данной работе применялась модель qwen2.5:7b.

```
self.model = "qwen2.5:7b"
```

Обращения к модели сделано отдельным методом ask_ollama(). В него передаётся текстовый запрос, после чего программа получает ответ от модели.

```
def ask_ollama(self, prompt):  
    response = ollama.generate(  
        model=self.model,  
        prompt=prompt  
    )  
  
    answer = response["response"]  
  
    return answer.strip()
```

Этот метод используется при анализе текста первой страницы статьи. Модель получает часть текста документа и пытается определить название статьи и авторов.

3.4.2. Определение названия статьи и авторов

После подключения модели была реализована автоматическая обработка первой страницы научной статьи. Это нужно для того, чтобы программа самостоятельно определяла название работы и авторов перед сохранением данных в датасет.

Решения этой задачи было создание метод `find_source_info()`. В него передаётся текст первой страницы pdf документа.

```
def find_source_info(self, first_page_text)
```

Программа формирует текстовый запрос для модели. В запросе указывается, что нужно найти название статьи и авторов только по первой странице документа.

```
prompt = (  
    "Найди название научной статьи и автора или авторов. "  
    "Ищи только в тексте первой страницы. "  
    "Ответь строго в таком виде:\n"  
    "Название: ...\n"  
    "Авторы: ...\n"  
    "Если данных нет, напиши unknown.\n\n"  
    + first_page_text[:3000]  
)
```

Запрос отправляется в модель через метод `ask_ollama()`.

```
answer = self.ask_ollama(prompt)
```

Программа разбирает полученный ответ и сохраняет найденное название статьи и авторов в отдельную структуру данных.

```
source_data = {  
    "title": title,  
    "authors": authors  
}
```

Такой способ позволил автоматически получать информацию о научной статье и сохранять её вместе с найденными текстовыми фрагментами.

3.5. Формирование итогового датасета

После поиска нужных фрагментов программа сохраняет результат в файл dataset.jsonl. Такой формат удобен тем, что каждая строка хранит данные по отдельной статье и может дальше использоваться для анализа или обучения модели.

сохранения результата делается через метод `save_result()`. В нём собираются имя файла, название статьи, авторы и найденные фрагменты.

```
output_data = {
    "file": file_name,
    "title": source_data["title"],
    "authors": source_data["authors"],
    "matches": result_blocks
}
```

После этого данные переводятся в JSON-строку и записываются в итоговый файл.

```
json_line = json.dumps(output_data, ensure_ascii=False)
output_file.write(json_line + "\n")
```

Перед началом новой обработки файл dataset.jsonl очищается, чтобы старые результаты не смешивались с новыми.

```
output_file = open("dataset.jsonl", "a", encoding="utf-8")
output_file.close()
```

В результате формируется датасет, где для каждой статьи сохраняются основные сведения и найденные утверждения о существовании и единственности.

3.6. Анализ результатов работы программы

После запуска программы был сформирован файл dataset.jsonl, в котором сохранились результаты обработки pdf документов. В итоговый датасет попали сведения о статье, название, авторы и найденные фрагменты текста.

Пример структуры сохранённых данных выглядит следующим образом.

```
{
  "file": "assets/elibrary_11674319_64387490.pdf",
  "title": "Обобщенно-правильные системы дифференциальных уравнений",
  "authors": "Т.М. Алдибеков",
  "matches": [{
    "page": 2,
    "type": "text",
    "start_index": 3837,
    "end_index": 4061,
    "fragment": "SpA(t)dt. (5) Теорема 1. Если система (1) имеет конечные  
обобщенные показатели относительно  $q(t) \in Q$ , то для обобщенной правильности  
системы (1) относительно  $q(t)$  необходимо существование точного предела  $S(q) = \lim_{t \rightarrow \infty} \frac{1}{t} \int_0^t q(t)dt$ "
  }],
}
```

По результатам работы можно сделать вывод, что программа корректно находит фрагменты, связанные с утверждениями о существовании и единственности. При этом часть текста после извлечения из PDF может содержать ошибки в формулах или отдельных символах. Потому нормализация текста очень важный этап.

Полученный датасет можно использовать для дальнейшей проверки, разметки или обучения модели на задаче поиска математических утверждений.

3.7. Вывод по разделу

В ходе разработки была создана программа для автоматической обработки научных pdf документов и формирования датасета. Программа выполняет чтение файлов, очистку текста, поиск утверждений о существовании и единственности, а также сохранение результатов в формате JSONL.

Дополнительно была реализована работа с нейросетевой моделью через Ollama для определения названия статьи и авторов. Полученный датасет можно использовать для дальнейшего анализа научных текстов и последующей обработки данных.

Выводы по разделу 2

Таблица 2

Выводы	Сформированные компетенции
Разработана программа для автоматической обработки научных pdf документов и формирования структурированных данных Реализованы чтение pdf файлов, очистка текста и поиск математических оценок и неравенств по ключевым словам Выполнено сохранение результатов обработки в формате JSON и TXT для дальнейшего анализа данных Реализована работа с нейросетевой моделью через Ollama для определения названия статьи и авторов	ПК-1. Способность разработки прикладного программного обеспечения, автоматизации работы с базами данных и документами, программирования бизнес-логики приложений, интеграции разнородных данных ПК-8 Способность выполнять интеллектуальный анализ больших данных

4. Заключение

В ходе прохождения производственной практики была разработана программа для автоматической обработки научных pdf документов и формирования датасета. В процессе работы были изучены особенности обработки научных текстов, работа с pdf файлами и использование инструментов Python для анализа данных.

Во время практики были получены навыки работы с библиотеками для извлечения и обработки текста, а также изучены способы применения нейросетевых моделей при анализе научных публикаций. Дополнительно была реализована работа с локальной языковой моделью через Ollama для автоматического определения названия статьи и авторов.

В ходе выполнения работы были реализованы очистка и нормализация текста, поиск утверждений о существовании и единственности, а также сохранение результатов в формате JSONL. Полученный датасет может использоваться для дальнейшего анализа научных текстов и последующей обработки данных.

Таким образом, цель производственной практики была достигнута. В процессе работы были закреплены теоретические знания и получены практические навыки разработки программных решений для обработки текстовой информации и подготовки данных для дальнейшего анализа.

5. Список использованной литературы

1. Работа с pdf файлами с помощью библиотеки fitz // Хабр. – URL: [Habr PyMuPDF](#) (дата обращения: 18.05.2026).
2. Извлечение текста при помощи PyMuPDF // PythonTalk. – URL: [PythonTalk PyMuPDF](#) (дата обращения: 20.05.2026).
3. Ollama от А до Я: как выбрать модель, настроить и использовать // Хабр. – URL: [Habr Ollama Guide](#) (дата обращения: 20.05.2026).
4. Ollama documentation // Ollama. – URL: [Ollama Documentation](#) (дата обращения: 25.05.2026).
5. PyMuPDF documentation // PyMuPDF Documentation. – URL: [PyMuPDF Documentation](#) (дата обращения: 23.05.2026).
6. Обработка PDF в Python: автоматизация и парсинг документов // Skypro Media. – URL: [Skypro PDF Python](#) (дата обращения: 24.05.2026).
7. Платформа Ollama: что это и как с ней работать // Skillbox Media. – URL: [Skillbox Ollama](#) (дата обращения: 24.05.2026).